

# “Red Neuronal Profunda para predicción meteorológica de precipitaciones”

**Autor/Autores:** Mulatillo A., Céspedes O., Inga G., Avila E., Saico M., Vargas A.

**Resumen-** El presente trabajo aborda la predicción de precipitaciones en Australia mediante la aplicación de redes neuronales artificiales. Para ello, se utilizó un conjunto de datos de aproximadamente 100,000 registros que incluye variables meteorológicas clave como temperatura, humedad y presión. La metodología consistió en el desarrollo de un modelo de clasificación binaria, para lo cual se evaluaron dos configuraciones experimentales. El objetivo principal fue garantizar una sensibilidad (recall) mínima del 80% para la clase 'Llueve', asegurando así la identificación correcta de la mayoría de los eventos pluviales del día siguiente. Como conclusión, se destaca la efectividad de las redes neuronales para generar pronósticos meteorológicos precisos, lo cual contribuye significativamente a una gestión más eficiente de los recursos.

## 1. Introducción

La predicción meteorológica ha venido siendo uno de los retos más importantes en la ciencia, con implicaciones en diversos sectores como agricultura, recursos hidráulicos, aviación o planificación urbana. Desde tiempos remotos se han realizado modelos físico-numéricos a fin de dar cobertura, sin embargo, siempre presentaron limitaciones en términos espaciales y temporales, sobre todo en casos donde la predicción se va a realizar a muy corto plazo.

La importancia de la predicción meteorológica llega a trascender al ámbito socioeconómico. Las pérdidas a nivel global ligadas a fenómenos meteorológicos escalan a valores mayores a 200 mil millones de dólares (CRED, 2024). En base a dicho contexto, la capacidad de predicción de eventos meteorológicos con antelación permite la implementación de medidas de mitigación que reduzcan dichas pérdidas.

Respecto al sector agrícola, la anticipación de lluvias llega a influir directamente en campos sobre la siembra, cosecha y aplicación de riego, afectando los rendimientos de cultivos. En el sector urbano, los sistemas de drenaje y gestión depende de pronósticos para la implementación de protocolos preventivos.

Ante la creciente disponibilidad de datos históricos, el avance de las capacidades computacionales y la necesidad de superar las limitaciones de los métodos convencionales, los enfoques basados en aprendizaje automático han adquirido una relevancia creciente. Mientras que los modelos numéricos tradicionales suelen requerir supuestos

estrictos y simplificaciones para representar los procesos físicos, los algoritmos de aprendizaje automático pueden identificar patrones complejos y no lineales directamente a partir de los datos observados, permitiendo capturar relaciones que los métodos clásicos no logran modelar adecuadamente.

Una aproximación binaria (llueve/no llueve) representa un punto de partida estratégico al centrar el foco en una variable decisiva con una amplia gama de aplicaciones. La investigación en este campo específico contribuye al avance científico meteorológico durante la elaboración de herramientas de utilidad práctica para la toma de decisiones en diversos sectores.

### Hipótesis:

La aplicación de redes neuronales de perceptrón multicapa con clasificación binaria en base a datos históricos de casi 10 años seguidos de observación climática en Australia, junto a diversas variables numéricas y categóricas, nos permitirá predecir con un recall mínimo de 80%, si lloverá o no el día siguiente al trabajar relaciones de variables atmosféricas que modelos típicos no podrían predecir de manera efectiva.

### Objetivos:

- Recopilar y procesar los datos de nuestro dataset proveniente de Kaggle, con variables predictoras clave como (temperatura, humedad relativa, presión atmosférica, velocidad del viento, etc).
- Diseño de una arquitectura de red neuronal por capas optimizada, experimentado con diferentes configuraciones de capas



ocultas, funciones de activación y tasas de aprendizaje.

- Evaluar el conjunto de características que represente variables predictivas relevantes en base a la influencia de cada variable predictora para la predicción de lluvia.
- Entrenar y evaluar las redes neuronales para predecir si habrá o no lluvia, siendo este nuestro objetivo principal.
- Priorizar recall sobre precisión para minimizar falsos negativos, es decir, que prediga que no habrá lluvia cuando en realidad sí habrá.
- Identificar principales factores que llegasen a limitar el rendimiento del modelo, proponiendo estrategias de mejora y sugerencias para el futuro.
- Examinar las implicaciones éticas y posibles sesgos en la predicción de lluvias a partir de las variables.

## 2. Trabajos relacionados

### **A pioneering approach to deterministic rainfall forecasting for wet period in the Northern Territory of Australia using machine learning [1]:**

El artículo aborda la predicción de precipitaciones durante el periodo húmedo en el territorio norte de Australia, para lograr esto emplea modelos de aprendizaje automático como regresión múltiple, red neuronal artificial y random forest. Para la optimización de hiperparámetros y evaluación de los modelos se utilizó el método de validación cruzada k-fold. Los resultados obtenidos demuestran un mayor rendimiento al utilizar redes neuronales a comparación de MR y RF, obteniendo valores menores de RMSE y rRMSE, y valores mayores en  $R^2$

### **A wavelet artificial neural network method for medium-term rainfall prediction in Queensland (Australia) and the comparisons with conventional methods [2]:**

El estudio propone el uso de un modelo híbrido Wavelet-Artificial Neural Network (W-ANN) para la precipitación mensual a 1, 3, 6 y 12 meses en Queensland (Australia), la metodología consiste en una etapa de preprocesamiento empleando la Transformada Wavelet y luego utiliza estos componentes procesados como entradas de una red neuronal artificial de perceptrón multicapa. Los resultados demuestran que este enfoque híbrido W-ANN supera significativamente en precisión a los métodos convencionales, logrando una reducción del RMSE promedio y siendo más confiables en la estimación de la precipitación máxima.

### **Machine Learning-Based Rainfall Prediction: Unveiling Insights and Forecasting for Improved Preparedness [3]:**

El estudio realiza un análisis comparativo exhaustivo de múltiples algoritmos de aprendizaje automático, incluyendo Random Forest, Decision Tree, Naive Bayes, Support Vector Machines (SVM) y Redes Neuronales Artificiales (ANN), para predecir la ocurrencia de lluvia en diversas localidades de Australia. Se realizó preprocesamiento de datos, análisis de valores atípicos, transformación cuantil y selección de características. Finalmente, se encontró que la Red Neuronal Artificial fue el modelo más preciso, alcanzando un 91% de precisión tras la selección de características.

## 3. Metodología

### ■ Enfoque(s) propuesto:

El presente estudio tiene como objetivo desarrollar un modelo de redes neuronales para clasificación binaria (Sí: Lloverá el día siguiente - No: No lloverá el día siguiente). Para ello, se utilizará un conjunto de [datos del clima en Australia](#).

Entre nuestras variables, tenemos:

- **Entradas del sistema:** Nuestras entradas son las 21 variables que se encuentran en el dataset, que describen temperatura, evaporación, dirección del viento, velocidad del viento, humedad, presión, proporción de nubes, entre otros. Las cuales serán preprocesadas
- **Salidas del sistema:** Nuestra salida será la predicción (Sí/NO) de lluvia al día siguiente

Para resolver el problema de predicción se emplearán redes neuronales recurrentes.

### **Proceso metodológico empleado:**

#### 1. Preparación de los datos

- Se analizarán los datos, teniendo en cuenta el porcentaje de datos vacíos. Así mismo se analizará qué filas son relevantes y qué filas se deberían eliminar para el correcto análisis del modelo.
- Conversión de variables categóricas del dataset a variables numéricas. Para ello, se analizará cuál es el tipo de codificación más adecuada, tomando en consideración la cantidad de datos diferentes y si la variable cuenta con distribución circular.
- Eliminación de variables que contengan información que puede ser explicada con otras variables.
- Detección de outliers con ayuda de diagramas de cajas.

#### 2. Análisis de correlación



- Se realizará un gráfico de matriz de correlación para analizar la relación entre las variables y poder eliminar aquellas variables que contengan una correlación mayor igual a 0.9 en valor absoluto.




Figura 1: Matriz de correlaciones

### 3. Separación del dataset

- Se realizará la separación del conjunto de datos en 80% para train\_val y 20% para test. (Train: 3082 datos Test: 7646 datos).




Figura 2: Train test split

### 4. Normalización de datos

- Se realizará un escalado sobre las variables numéricas, debido a que tienen valores en diferentes escalas entre sí, para ello se usarán técnicas como Standard Scaler o MinMax Scaler evaluando con cuál se obtienen mejores resultados.

### 5. Redes neuronales

- Se asignará un peso a cada entrada dependiendo de su importancia para la predicción del modelo.
- Se seleccionará la función de activación más adecuada, Relu para las capas intermedias y Sigmoid para la capa final ya que es un problema de clasificación binaria.
- Se diseñará una arquitectura adecuada para la red neuronal (número de neuronas, número de capas ocultas y la tasa de

aprendizaje en caso realicemos ajustes en el optimizador).




Figura 3: Modelo de red neuronal con capas profundas

### 6. Análisis de resultados

- Se realizarán gráficas de las métricas Accuracy y Lost para evaluar su evolución durante el entrenamiento.
- Se realizará una matriz de confusión que nos permita comparar las predicciones realizadas por el modelo con los valores reales.
- Se realizará un reporte de clasificación en el que se muestran las métricas de Precision y Recall de la variable respuesta en base a la matriz de confusión.

|            |          | Clase predicha |          |
|------------|----------|----------------|----------|
|            |          | Positiva       | Negativa |
| Clase real | Positiva | TP             | FN       |
|            | Negativa | FP             | TN       |

Figura 4: Matriz de confusión

### 4. Experimentación y Resultados

#### ■ Setup experimental:

#### - Datos utilizados:

Se obtuvieron los datos de Kaggle, del cual se recolectó un dataset que contiene 10 años de observación diaria del clima desde diferentes estaciones a lo largo de diferentes ciudades de Australia. Originalmente, el dataset contenía más de



100000 registros con 23 variables, incluyendo la objetivo.

<https://www.kaggle.com/datasets/arunavakr/chakraborty/australia-weather-data>

#### - Métricas de evaluación:

Las métricas de evaluación que se usaron fueron:

- **Accuracy:** Proporción de predicciones correctas
- **Precision:** Capacidad de no clasificar negativos como positivos
- **Recall:** Capacidad de la detección de todos los positivos reales
- **AUC-ROC:** Capacidad discriminativa que posee el modelo en general.
- **Loss:** Error de clasificación durante la fase de entrenamiento..

#### - Experimentos:

Entre los experimentos realizados se tiene el empleo de la librería Keras de Tensorflow para la creación de las redes neuronales. Se trabajó como estrategia de validación una división inicial (64% train, 16% validation y 20% test)

#### Experimento 1: Arquitectura de red neuronal #1

Se realizó un escalado **StandardScaler** para las variables predictoras, trabajaron con diferentes modelos, uno simple de 2 capas ocultas, uno complejo de 6 capas ocultas, pero el definitivo fue de 4 capas ocultas aparte de la de salida, con una cantidad de neuronas de: 128, 64, 32, 16 y 1. Función de activación Relu para capas ocultas, ya que evitan el problema del desvanecimiento del gradiente y función de activación Sigmoide para la capa de salida, ya que es un problema de clasificación binaria.

#### Recall obtenido en modelos:

**Red simple:** 78.21%

**Red media:** 79.31%

**Red compleja:** 84.54%

Para la compilación del modelo, se usó optimizador Adam con las métricas clásicas de **accuracy** y función de pérdida **binary\_crossentropy**, ya que este último es más coherente con capa de salida sigmoide.

Para manejar el desbalance se usaron pesos para las clases en proporción a la relación de los datos en el target con `compute_class_weight`.




Gráfico 1: Evolución del accuracy - Experimento 1




Gráfico 2: Evolución del loss - Experimento 1




Gráfico 3: Matriz de confusión - Experimento 1

La gráfica de accuracy (Gráfico 1) muestra que el rendimiento en el entrenamiento va mejorando a lo largo de las 50 épocas convergiendo en aproximadamente 0.82, pero la curva de validación, que converge alrededor de 0.79, se muestra inestable y sin una mejora sostenida, esto indica un ligero sobreajuste.



La gráfica de loss (Gráfico 2) muestra como la pérdida en el entrenamiento disminuye de forma continua llegando a converger en 0.38, mientras que la curva de validación tiene una disminución inicial pero posteriormente presenta picos llegando a converger en 0.46, mostrando inestabilidad.

- **Classification report:**

|                  | Precision | Recall | F1-Score |
|------------------|-----------|--------|----------|
| <b>No Llueve</b> | 0.95      | 0.79   | 0.86     |
| <b>Llueve</b>    | 0.52      | 0.84   | 0.64     |

La precisión de 52% nos indica que de todas las predicciones que realiza

### Experimento 2: Arquitectura de red neuronal #2

Se realizó un escalado **MinMax** para las variables predictoras. Para la construcción de la red neuronal, se usaron también **4 capas ocultas**, de **64, 32, 16 y 8 neuronas**, con **función de activación Relu** más la capa de salida de una sola neurona con función de activación sigmoide.

Para la compilación del modelo, se usó optimizador Adam con métrica **binary\_accuracy** en lugar de accuracy y función de pérdida **binary\_crossentropy**, ya que estos son más coherentes con la capa de salida sigmoide.

Además se probaron a usar **callbacks** como **EarlyStopping** que detiene el entrenamiento cuando el modelo deja de mejorar en la métrica monitoreada (por ejemplo, val\_loss). y **ReduceLROnPlateau** que reduce la tasa de aprendizaje cuando la métrica monitoreada (val\_loss) deja de mejorar. Permite que el modelo aprenda mejor al reducir la tasa de aprendizaje en fases avanzadas, evita quedar atrapado en mínimos locales poco óptimos y acelera la convergencia al ajustar la tasa según el progreso

En este experimento se dejaron sin balancear los pesos de las clases del target y aunque mejoró la precisión de predicción, el recall bajó considerablemente.

El tiempo de entrenamiento de este modelo fue de aproximadamente 6 minutos.




Gráfico 4: Evolución del Binary Accuracy - Experimento 2




Gráfico 5: Evolución del loss - Experimento 2

- **Classification report:**

|                  | Precision | Recall | F1-Score |
|------------------|-----------|--------|----------|
| <b>No Llueve</b> | 0.89      | 0.98   | 0.93     |
| <b>Llueve</b>    | 0.74      | 0.36   | 0.49     |

La gráfica de evolución del binary accuracy (Gráfico 5) nos indica que tanto las curvas de entrenamiento como de validación tienden a converger en 0.89, un valor cercano a 1, mientras que por el lado del loss también ambas tienden a valores cercanos a 0.

Este experimento resuelve el problema de predicción en la mayoría de casos tanto para cuando sí o no lloverá mañana, pero el recall en este caso es mucho menor al del primer experimento.

**Experimento elegido:** Se optó por usar el Experimento 1, ya que sus resultados van más acorde con los objetivos de la investigación, es preferible sacrificar precisión para capturar la mayor cantidad de precipitaciones posibles.

## 5. Conclusión





Este estudio exploró la viabilidad de usar los datos de observación de 10 años al clima de Australia para la predicción de precipitaciones.

Se realizó el preprocesamiento tomando en cuenta las variables relevantes, realizando imputación de nulos donde se requiera, usando One Hot Encoding en variables categóricas ya que no existe relación de orden.

En base a los resultados obtenidos por el mejor modelo en la **experimentación 1**, podemos concluir que es posible predecir, con un precisión de 52% junto a un recall de 84%, si lloverá al día siguiente.

No tan óptimo para fines prácticos, ya que tenderá a devolver falsos positivos, pero el recall es considerable, lo cual toma mayor relevancia ya que un falso negativo es aún más crítico. Predecir que no lloverá cuando sí lo hará conlleva muchos más problemas a la población que estará menos preparada.

Para llegar a estos resultados, consideramos óptimo implementar redes neuronales. La arquitectura empleada mediante capas permitió la generación de modelos robustos, el valor obtenido de AUC en el sistema de redes neuronales complejo respalda ello (0.894), obteniendo un modelo altamente discriminatorio. Las cuales nos arrojaron resultados positivos para nuestro objetivo principal. Dicho valor representa valores mayores a los presentados en otros algoritmos presentes y modelos convencionales que han venido siendo empleados en el tiempo.

El hecho de trabajar con datos pertenecientes a hechos meteorológicos en diversas zonas geográficas tienden a representar datasets que requieren un preprocesamiento crítico. La eliminación de diversos outliers inconsistentes, imputación de valores faltantes junto a la normalización son vitales para lograr un entrenamiento efectivo. A su vez destacamos la relevancia de la ponderación automática en el balance de clases, optimizando la detección de la clase minoritaria.

## 6. Sugerencias de trabajos futuros

En el enfoque presentado se puede mejorar el balance de los datos, la categoría Rain Tomorrow cuenta con un desbalance muy desproporcionado ya que los datos presentan una proporción de 80-20, lo que podría causar un sesgo al momento de predecir si lloverá o no al día siguiente.

Por otro lado, se puede utilizar esta técnica para poder predecir la lluvia en regiones de otros

países, además, sería útil poder ampliar el número de días que se puede predecir la lluvia sin que el algoritmo disminuya de manera considerable su precisión.

Además, así como se está considerando para casos de predicción de precipitaciones, también se podría usar para algoritmos de predicción de desastres naturales en beneficio de la población para que se encuentre alerta.

## 7. Implicancias éticas

Una implicancia ética a resaltar es la posible discriminación territorial dado que las zonas con una menor densidad de datos podrían recibir predicciones menos confiables lo cual podría afectar de manera negativa sus decisiones en agricultura, logística o preparación ante posibles desastres.

Los modelos meteorológicos no son deterministas, sino son netamente probabilísticos, y es éticamente incorrecto comunicar predicciones como certezas. Los errores pueden tener impactos reales en agricultura, transporte, gestión de desastres y recursos hídricos.

Además, como muchos modelos de IA, estamos trabajando con “cajas negras”. Los usuarios finales a quienes se les hará entrega del modelo podrán tomar decisiones sin entender los límites del mismo y no se podrán explicar el por qué es que devuelve falsos positivos al realizar predicciones de lluvia. Esto se vuelve crítico cuando se trata de emergencias y el resultado divulgado es falsos positivos o falsos negativos.

Por último se debe considerar la responsabilidad del error, ¿Quién asumirá las consecuencia en el momento que alguna predicción falle? Al ponerse en juegos vidas y diversos medios de subsistencia, las autoridades competentes no puede eximir sus responsabilidades y deberes ante la transparencia, supervisión y rendición de cuentas

## 8. Link del repositorio del trabajo

Repositorio de GitHub usado para el desarrollo de la presente Tarea Académica:

[https://github.com/EnzoIdk/TA\\_IA\\_2025-2](https://github.com/EnzoIdk/TA_IA_2025-2)

## 9. Declaración de contribución de cada integrante

Describir los aportes de cada integrante al proyecto.



- a. Ariana Mulatillo (20222999): Redacción de introducción, objetivos, metodología, sugerencia de trabajos futuros y parte de implicancias éticas.
- b. Oscar Céspedes (20221473): Redacción de resumen, introducción, correcciones y búsqueda de fuentes.
- c. Enzo Avila (20220954): Formulación de temática y elaboración de gráficas.
- d. Gonzalo Inga (20220694): Redacción de los objetivos y búsqueda de fuentes.
- e. Mario Saico (20220867): Redacción de la metodología. Elaboración del código final.
- f. Alvaro Vargas (20222145): Revisión, metodología. Implicancias éticas.

## 10. Referencias

- [1]. Farooq, R., Imteaz, M.A. & Mekanik, F. A pioneering approach to deterministic rainfall forecasting for wet period in the Northern Territory of Australia using machine learning. *Earth Sci Inform* 18, 224 (2025). <https://doi.org/10.1007/s12145-025-01724-0>
- [2]. Ghamariadyn, M., & Imteaz, M. A. (2021). *A wavelet artificial neural network method for medium-term rainfall prediction in Queensland (Australia) and the comparisons with conventional methods*. *International Journal of Climatology*, 41(Suppl. 1), E1396–E1416. [https://www.researchgate.net/profile/Meysam-Ghamariadyn/publication/343289267\\_A\\_wavelet\\_artificial\\_neural\\_network\\_method\\_for\\_medium-term\\_rainfall\\_prediction\\_in\\_Queensland\\_Australia\\_and\\_the\\_comparisons\\_with\\_conventional\\_methods/links/609a2e4592851c490fcd816/A-wavelet-artificial-neural-network-method-for-medium-term-rainfall-prediction-in-Queensland-Australia-and-the-comparisons-with-conventional-methods.pdf](https://www.researchgate.net/profile/Meysam-Ghamariadyn/publication/343289267_A_wavelet_artificial_neural_network_method_for_medium-term_rainfall_prediction_in_Queensland_Australia_and_the_comparisons_with_conventional_methods/links/609a2e4592851c490fcd816/A-wavelet-artificial-neural-network-method-for-medium-term-rainfall-prediction-in-Queensland-Australia-and-the-comparisons-with-conventional-methods.pdf)
- [3]. Ramírez, J., Chen, L., & Smith, K. (2023). Comparative Analysis of Machine Learning Models for Rainfall Prediction in Australia. 2023 IEEE International Conference on Data Science and Advanced Analytics (DSAA) <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10320349>
- [4]. Centre for Research on the Epidemiology of Disasters (CRED). (2025). 2024 Disasters in Numbers. Brussels, Belgium: CRED. [https://files.emdat.be/reports/2024\\_EMDAT\\_report.pdf](https://files.emdat.be/reports/2024_EMDAT_report.pdf)

