

“Algoritmo de predicción de hechos delictivos en el Perú”

Autor/Autores: Mulatillo A., Céspedes O., Inga G., Avila E., Saico M., Vargas A.

Resumen- La delincuencia es un problema que aqueja a la población peruana a diario, ninguno está completamente seguro. El presente trabajo académico plantea como objetivo predecir la cantidad de delitos a ocurrir por departamento mediante un algoritmo de regresión. Dicho algoritmo será entrenado con datos históricos de denuncias en diferentes departamentos del país a lo largo de los años, además de ser alimentado con variables predictoras adicionales en base a informes sociodemográficos del INEI. Se realizará el preprocesamiento necesario con las variables disponibles, junto a la separación adecuada de los datos para entrenamiento y testeo. Se espera desarrollar un modelo que sea capaz de predecir con un porcentaje de aciertos superior al 75% de los casos luego de las pruebas finales.

1. Introducción

La alta incidencia delictiva en el país es un problema recurrente. Es muy común que en nuestro círculo cercano hayamos sido víctimas de la delincuencia, lo que denota un crecimiento en los índices de delincuencia. Comúnmente, el actuar de las autoridades policiales es de manera reactiva, simplemente se basan en datos históricos sin un análisis de por medio respecto a patrones de los mismos, dicha limitación deriva en una falta de optimización de recursos y estrategias preventivas ineficientes. La relevancia del problema radica en su influencia en la población peruana, con impacto directo en aspectos como la seguridad ciudadana, calidad de vida y desarrollo sostenible. Por ello se justifica la necesidad de la implicación de Inteligencia Artificial para la transformación de datos disponibles en conocimiento aplicable para las autoridades competentes.

Hipótesis:

La aplicación de algoritmos de clasificación de machine learning en base a datos históricos, junto a variables socioeconómicas permiten la elaboración de un modelo predictivo con una capacidad de identificación de zonas con un alto índice delictivo, con una precisión del 75% como mínimo. Dicho modelo daría evidencia de correlaciones entre factores diversos como la diversidad poblacional y la ocurrencia de diversos delitos.

Objetivos:

- Recopilar y procesar datos provenientes de fuentes oficiales para consolidar un conjunto de datos único y consistente.

- Construir un conjunto de características que represente variables predictivas relevantes para la ocurrencia de delitos.
- Entrenar y evaluar modelos predictivos para identificar áreas con mayor cantidad de delitos.
- Analizar los patrones temporales de incidencia delictiva, identificando los periodos con mayor frecuencia.
- Examinar las implicaciones éticas y posibles sesgos en la predicción de delitos a partir de variables sociales.

2. Trabajos relacionados

An Evaluation of Compstat's Effect on Crime [1]:

Este estudio busca evaluar el impacto del uso del sistema de gestión Compstat, creado por el Departamento de Policía de Nueva York en 1994. El sistema se encarga de recolectar hechos delictivos, incluyendo información sobre zonas geográficas, nivel socioeconómico, entre otros, los cuales servían de entrada para algoritmos de predicción. Luego de evaluar resultados, se concluye que el sistema permitió realizar tácticas eficaces que ayudaron a disminuir la delincuencia en la ciudad.

IA en la seguridad y delincuencia [2]:

Esta tesis aborda fundamentalmente las consecuencias éticas del uso de IA para predicciones de hechos delictivos en la Unión Europea. Se indica que en base a estudios de impactos por la región, no existe una ventaja significativa que genere paradigmas delictivos precisos que compensen el uso de información sesgada, además que en algunos casos incluso ignora los derechos de privacidad de la información.



Smart criminal justice: exploring the use of algorithms in the Swiss criminal justice system [3]

Este estudio cualitativo exploró la inclusión de sistema predictivos en el sistema de justicia suizo. Los resultados denotan que, si bien los sistemas trabajan con un bajo nivel de automatización, ofrecen beneficios significativos en eficiencia. No obstante, se resalta la importancia de evaluar sus implicancias legales y sociales, una justicia implementada de manera ética y efectiva.

Prediction Web Application Based on a Machine Learning Model to Reduce Robberies and Thefts Rate in Los Olivos, San Martín De Porres and Comas [4]:

Este estudio presenta una aplicación web predictiva que emplea un modelo de machine learning que utiliza datos históricos de criminalidad para predecir tasas de delincuencia. Este estudio concluye que el modelo de machine learning demuestra una alta capacidad predictiva cercana a los valores reales en ciertas zonas.

3. Metodología

■ Enfoque(s) propuesto:

El presente estudio tiene como objetivo desarrollar un modelo de predicción de la cantidad de delitos por departamento en función de variables relacionadas con el entorno en que ocurren. Para ello, se utilizará un conjunto de datos históricos que contiene el número de delitos registrados por zona geográfica, obtenido de la Plataforma Nacional de Datos Abiertos. Con el fin de mejorar la capacidad predictiva del modelo, se incorporarán variables adicionales provenientes de fuentes oficiales de carácter social y económico, tales como tasa de natalidad, densidad poblacional, nivel educativo, entre otras, se optó por usar informes estadísticos del INEI por departamento.

Estas variables se integrarán al dataset principal mediante procesos de limpieza, normalización. Algunas de ellas serán variables derivadas, generadas a partir de cálculos o combinaciones entre indicadores existentes (por ejemplo, la cantidad de delitos de los meses anteriores).

El problema se plantea como un sistema de predicción espacio-temporal, en el cual se busca estimar la cantidad de delitos en distintas zonas y periodos de tiempo, considerando la interacción entre factores socioeconómicos y las características históricas de cada territorio.

- **Entradas del sistema:** Nuestras entradas son los datos históricos, características temporales y espaciales.

- **Salidas del sistema:** Nuestra salida será la evaluación de la correlación entre departamentos y los hechos delictivos registrados, serán representados mediante matriz de probabilidades y mapas de calor.

Para resolver el problema de predicción se emplearán dos algoritmos supervisados de regresión: Regresión Lineal Múltiple y Regresión KNN (K-Nearest Neighbors).

1. Algoritmo de Regresión Lineal Múltiple

Este modelo se define mediante la ecuación general:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

donde:

- $\hat{y}$: Cantidad de delitos estimada.
- x_i : Variables predictoras (por ejemplo, PBI, población, natalidad, modalidad, etc.),
- β_i : Coeficientes que indican el peso de cada variable en la predicción.

Con respecto a su aplicación al problema, el modelo se entrenará con datos agrupados por ubigeo y mes, se utilizarán como variables independientes las columnas enriquecidas con factores demográficos y económicos, el modelo calculará los coeficientes que mejor expliquen la variación del número de delitos y se analizará la fuerza de correlación entre cada variable y la cantidad de delitos para identificar cuáles influyen más en la predicción.

Este algoritmo permitirá obtener una ecuación general del comportamiento delictivo y servirá como referencia base para comparar otros modelos más complejos.





Figura 1. Representación de regresión lineal

2. Algoritmo de Regresión KNN

El segundo algoritmo propuesto es el de Regresión KNN, el cual estima la cantidad de delitos de un ubigeo basándose en la media de los k ubigeos más similares en sus características predictoras.

Para este modelo se definirá un valor inicial de k (por ejemplo, 5, aún no definido) que representará el número de zonas vecinas consideradas para cada predicción. Además, la similitud entre ubigeos se medirá mediante distancia euclidiana entre los vectores de características normalizados. Este modelo permitirá capturar patrones locales o comportamientos delictivos similares entre departamentos con condiciones socioeconómicas parecidas y se prevé evaluar distintos valores de k en la etapa experimental para analizar su influencia en la precisión del modelo.

Figura 2. Representación de KNN para valor $K=5$

Proceso metodológico general

- Preparación del conjunto de datos:** Limpieza de registros, unificación de ubigeos y generación de variables adicionales en base a datos como cantidad de delitos en 3 meses anteriores. Asimismo, variables adicionales obtenidas de estadísticas departamentales del INEI como PBI, población, . Además de la generación de datos adicionales necesarios usando IA.
- Definición de los algoritmos:** Implementación de los modelos de Regresión Lineal y Regresión KNN como dos funciones independientes.
- Entrenamiento y prueba:** Método "train_test_split" para división del conjunto de datos en subconjuntos de entrenamiento (80 %) y prueba (20 %).
- Comparación de resultados:** los modelos se evaluarán con métricas de regresión como R^2 , MAE y MSE.

- Visualización y análisis:** representación gráfica de las predicciones frente a los valores reales y elaboración de mapas de calor con los niveles estimados de criminalidad.

4. Experimentación y Resultados

■ Setup experimental:

- Describir datos usados (o método para obtenerlos) (si aplica).
- Describir las métricas de evaluación.
- Describir los experimentos hechos (qué componentes/parámetros/escenarios se probaron, qué valores, qué estrategia de validación).

Los experimentos deben ser planificados para poder caracterizar/comparar los enfoques desarrollados. Aquí algunas preguntas que deben responder los experimentos:

- ¿El enfoque desarrollado resuelve siempre el problema?
- ¿Qué tan eficientemente lo resuelven?
- ¿Cuál es el desempeño comparado con otros modelos o técnicas de referencia?
- ¿Cómo influyen los parámetros del enfoque en su desempeño?

■ Resultados y Discusión:

- Presentar resultados numéricos generados en los experimentos. Hacer un análisis de dichos resultados.

La presentación de los resultados debe facilitar el entendimiento. En general se deben usar figuras y/o tablas. Recuerde, todos los resultados deben interpretarse. Esforzarse para explicar el formato de las curvas presentadas, dar detalles del tiempo de simulación.

5. Conclusión

Dar las conclusiones principales con base en los resultados obtenidos y a lo que fue planteado en su hipótesis, ¿qué se puede decir del o los enfoques desarrollados y/o del problema abordado?

6. Sugerencias de trabajos futuros

Indicar, por ejemplo: ¿qué cosas se pueden mejorar del enfoque?, ¿qué otros posibles problemas podrían abordarse con el enfoque?

7. Implicancias éticas

Indicar qué implicancias éticas podría generar el trabajo desarrollado de ser escalado (sesgos, posible afectación a la seguridad/privacidad de

usuarios, posibilidad de ataques y robo de datos, etc). Sugiera formas de abordar dichos problemas

Armas de destrucción matemática. Capítulo 5.

8. Link del repositorio del trabajo

Repositorio de GitHub usado para el desarrollo de la presente Tarea Académica:

https://github.com/Enzoldk/TA_IA_2025-2

9. Declaración de contribución de cada integrante

Describir los aportes de cada integrante al proyecto.

- a. Ariana Mulatillo (20222999): Redacción de introducción, objetivos y metodología.
- b. Oscar Céspedes (20221473): Redacción de resumen, introducción, correcciones y búsqueda de fuentes.
- c. Enzo Avila (20220954): Formulación de temática, redacción de introducción y búsqueda de fuentes.
- d. Gonzalo Inga (20220694): Redacción de los objetivos y búsqueda de fuentes.
- e. Mario Saico (20220867): Redacción de la metodología.
- f. Alvaro Vargas (20222145): Revisión, metodología.

10. Referencias

- [1]. Jang, H., Hoover, L. T. & Joo, H.-J. (2010). An Evaluation of Compstat's Effect on Crime: The Fort Worth Experience. *Police Quarterly*, 13(4), 387-412.
- [2]. Pellejero Cuenca, D. (2023). IA en la seguridad y delincuencia: Implicaciones político criminales

para el futuro. Universitat Oberta de Catalunya (UOC).

- [3]. Simmler, M., Brunner, S., Canova, G. et al. Smart criminal justice: exploring the use of algorithms in the Swiss criminal justice system. *Artif Intell Law* 31, 213-237 (2023). <https://doi.org/10.1007/s10506-022-09310-1>
- [4]. Sanchez, M., Estefano, L., Padilla, Z., Antonio, C., & Castañeda, P. S. (2024). Prediction Web Application Based on a Machine Learning Model to Reduce Robberies and Thefts Rate in Los Olivos, San Martín de Porres and Comas. En F. G. Penalvo, K. Aberer, & M. Marchiori (Eds.), *Proceedings of the 20th International Conference on Web Information Systems and Technologies, WEBIST 2024* (pp. 191-198). (International Conference on Web Information Systems and Technologies, WEBIST - Proceedings). Science and Technology Publications, Lda. <https://doi.org/10.5220/0012906800003825>
- [5]. S. Raschka & V. Mirjalili (2019). *Python Machine Learning*. Third Edition. California: O'Reilly Media.
- [6]. Denuncias policiales | Plataforma Nacional de Datos Abiertos. (s. f.). <https://www.datosabiertos.gob.pe/dataset/denuncias-policiales-1>
- [7]. PERU Instituto Nacional de Estadística e Informática INEI. (n.d.). <https://www.inei.gob.pe/estadisticas/indice-tematico/sociales/>

Nota importante:

Figuras y tablas

- Cada figura debe ser leída y comprendida sin necesidad de recurrir a la descripción a lo largo del texto.
- Todos los símbolos usados deben ser explicados en la leyenda.

