

predicción de precipitaciones en Australia





Grupo 03

- Mulatillo, Ariana (20222999)
- Céspedes, Oscar (20221473)
- Inga, Gonzalo (20220694)
- Avila, Enzo (20220954)
- Saico, Mario (20220867)
- Vargas, Alvaro (20222145)



Introducción

- Aprendizaje automático
- Redes Neuronales
- Problema de clasificación binaria
- Llueve / No llueve mañana





Objetivos


- Recopilar y procesar los datos de nuestro dataset proveniente de Kaggle.
- Diseño de una arquitectura de red neuronal por capas optimizada.
- Evaluar el conjunto de características que represente variables predictivas relevantes.
- **Entrenar y evaluar las redes neuronales para predecir si habrá o no lluvia.**
- **Priorizar recall sobre precisión para minimizar falsos negativos.** (Predecir que no llueve cuando en realidad sí)
- Identificar principales factores limiten el rendimiento del modelo.
- Examinar las implicaciones éticas y posibles sesgos en la predicción de lluvias.

Metodología

1. Preparación de los datos
2. Análisis de correlación
3. Separación del dataset
4. Normalización de datos
5. Redes neuronales
6. Análisis de resultados



Proceso metodológico general





Diccionario de datos

- Location - Ciudad
- MinTemp - La temperatura mínima durante un día particular. (grados Celsius),
- MaxTemp - La temperatura máxima durante un día particular. (grados Celsius)
- Rainfall - Precipitación durante un día particular. (milímetros)
- Evaporation - Evaporación durante un día particular. (milímetros)
- Sunshine - Sol brillante durante un día particular. (horas)
- WindGusDir - Dirección de la ráfaga más fuerte durante un día particular. (16 puntos cardinales)
- WindGuSpeed - Velocidad de la ráfaga más fuerte durante un día particular. (Km/h)
- WindDir9am - Dirección del viento durante los 10 minutos anteriores a las 9 am. (puntos cardinales)
- WindDir3pm - Dirección del viento durante los 10 minutos anteriores a las 3 pm. (puntos cardinales)
- WindSpeed9am - Velocidad del viento durante los 10 minutos anteriores a las 9 am. (Km/h)
- WindSpeed3pm - Velocidad del viento durante los 10 minutos anteriores a las 3 pm. (Km/h)
- Humidity9am - Humedad del viento a las 9 am. (porcentaje)
- Humidity3pm - Humedad del viento a las 3 pm. (porcentaje)
- Pressure9am - Presión atmosférica a las 9 am. (hectopascales)
- Pressure3pm - Presión atmosférica a las 3 pm. (hectopascales)
- Cloud9am - Porciones del cielo oscurecidas por nubes a las 9 am. (octavos)
- Cloud3pm - Porciones del cielo oscurecidas por nubes a las 3 pm. (octavos)
- Temp9am - Temperatura a las 9 am. (grados Celsius)
- Temp3pm - Temperatura a las 3 pm. (grados Celsius)
- RainToday - Si hoy llueve, entonces 'Yes'. Si no llueve, entonces 'No'.
- **RainTomorrow** - Si mañana llueve entonces 1 (Yes). Si mañana no llueve entonces 0 (No). Variable target.

1. Preparación de los datos


- Se analizarán los datos, teniendo en cuenta la importancia de variables junto a su porcentaje de datos vacíos.
- Imputar nulos (reemplazar con moda en variables categóricas).
- Conversión de variables categóricas del dataset a variables numéricas.
- Detección de outliers con ayuda de boxplots.






2. Análisis de correlación

- Se realizará un gráfico de matriz de correlación y eliminar aquellas variables que contengan una correlación mayor igual a 0.9.



3. Separación del dataset

- Se realizó una división inicial de todo el dataset 80% train_val y 20% test.
- El 80% del dev_train set se dividió en 80% para train (64% total dataset) y 20% para validation (16% total dataset)



4. Normalización de datos

Se realizará un escalado sobre las variables numéricas, debido a que tienen valores muy altos.

Experimento 1	Experimento 2
Se realizó un escalado StandardScaler para las variables predictoras	Se realizó un escalado MinMax para las variables predictoras

$$z = \frac{x - \mu}{\sigma}$$

μ = Mean

σ = Standard Deviation

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

5. Redes Neuronales

- Se asignará un peso a cada entrada dependiendo de su importancia para la predicción del modelo.
- Se seleccionará la función de activación más adecuada, Relu para las capas intermedias y Sigmoid para la capa final ya que es un problema de clasificación binaria.
- Se diseñará una arquitectura adecuada para la red neuronal (número de neuronas, número de capas ocultas y la tasa de aprendizaje).

Experimento 1	Experimento 2
4 capas ocultas aparte de la de salida, con una cantidad de neuronas de: 128, 64, 32, 16 y 1. Función de activación Relu para capas ocultas y función de activación Sigmoide para la capa de salida	4 capas ocultas, de 64, 32, 16 y 8 neuronas, con función de activación Relu más la capa de salida de una sola neurona con función de activación sigmoide.

6. Análisis de resultados

- Se realizarán gráficas de las métricas Accuracy y Loss para evaluar su evolución durante el entrenamiento.
- Se realizará una matriz de confusión que nos permita comparar las predicciones realizadas por el modelo con los valores reales.
- Se realizará un reporte de clasificación en el que se muestran las métricas de Precision y Recall de la variable respuesta.


Experimento 1:

Red simple	Red media	Red compleja
Loss (pérdida): 0.4526 Accuracy: 80.93% Precision: 53.96% Recall: 76.63% AUC: 0.8766	Loss (pérdida): 0.4540 Accuracy: 79.75% Precision: 51.80% Recall: 83.08% AUC: 0.8908	Loss (pérdida): 0.4575 Accuracy: 79.98% Precision: 52.10% Recall: 84.48% AUC: 0.8944


6. Análisis de resultados

Experimento 1:

Evolución del Accuracy durante el entrenamiento




Evolución del loss durante el entrenamiento



6. Análisis de resultados

Experimento 1:





● Classification report:

	Precision	Recall	F1-Score
No Lluve	0.95	0.79	0.86
Lluve	0.52	0.84	0.64

6. Análisis de resultados

Experimento 2:



6. Análisis de resultados

Experimento 2:

- **Classification report:**

	Precision	Recall	F1-Score
No Lluvia	0.89	0.98	0.93
Lluvia	0.74	0.36	0.49


Conclusiones finales

- El mejor modelo de la experimentación 1, dio los valores de precisión de 52% junto a un recall de 84%, para predecir si lloverá al día siguiente.
- Tiende a devolver falsos positivos, no es tan optimo a modelo práctico, sin embargo, los falsos negativos son minoritarios.
- Valores de AUC robustos
- Preprocesamiento y ponderación automática vitales para el entrenamiento




Sugerencias de trabajos futuros

- Mejorar balance de datos. Balance actual pésimo de 80-20.
- Uso de algoritmo de predicción en otros países.
- Uso de algoritmo de predicción en desastres naturales.



Implicancias éticas

- Discriminación territorial, zonas con una menor densidad de datos podrían recibir predicciones menos confiables.
- Modelos meteorológicos no son deterministas, sino son netamente probabilísticos, y es éticamente incorrecto comunicar predicciones como certezas.
- Los errores pueden tener impactos reales en agricultura, transporte, gestión de desastres y recursos hídricos.
- Los usuarios finales podrán tomar decisiones sin entender los límites del mismo.
- Responsabilidad del error: ¿Quién asumirá las consecuencia cuando alguna predicción falle





MICHISISTEMA